




FastAPI 多模型 AI 架构流程图




代码文件分层架构图



单次请求执行时序图



核心模块职责简图



整体流程

1. 前端 Streamlit 发请求 → `/agent/chat`
2. FastAPI 统一接口 根据 model 路由到 qwen 或 deepseek
3. 对应模型 调用 API 生成回答
4. 通义千问/DeepSeek 会把对话存到 SQLite 数据库
5. 返回回答 给前端显示
6. 前端 展示聊天记录

1. fastapi_base.py

```
# 导入 Pydantic 的 BaseModel, 用于定义**请求数据格式** (校验+自动文档)
from pydantic import BaseModel

# 导入类型注解工具:
# Optional = 可选 (可以不传)
# List = 列表
# Literal = 固定枚举值 (只能选指定的内容)
from typing import Optional, List, Literal

# ===== 请求模型 =====
# 定义【通用聊天请求】的参数格式
class ChatRequest(BaseModel):
    user_id: str          # 字符串: 用户唯一ID (必须传)
    prompt: str           # 字符串: 用户输入的问题 (必须传)
    stream: bool = False  # 布尔: 是否流式输出, 默认关闭
    temperature: float = 0.7 # 浮点数: 生成温度 (0=严谨, 1=发散)
    max_tokens: int = 1024 # 整数: 最大生成字数, 默认1024
```

```

history: Optional[List[dict]] = None # 可选: 聊天历史 (列表套字典), 不传就是None

# 定义【智能体统一请求】参数格式
class AgentRequest(BaseModel):
    # 只能是 qwen 或 deepseek, 传别的会直接报错
    model: Literal["qwen", "deepseek"]
    prompt: str # 用户问题
    user_id: str # 用户ID
    stream: bool = False # 是否流式
    temperature: float = 0.7 # 温度

```

作用

- 这是接口参数校验文件
- 前端传参必须符合这里的格式
- FastAPI 会自动生成接口文档

2. database.py 详解

```

# SQLAlchemy 核心工具:
# create_engine = 创建数据库连接
# Column = 表字段
# Integer/String/Text/DateTime = 字段类型
from sqlalchemy import create_engine, Column, Integer, String, Text, DateTime

# declarative_base = 定义数据库表的基类
from sqlalchemy.ext.declarative import declarative_base

# sessionmaker = 创建数据库会话
# Session = 会话类型注解
from sqlalchemy.orm import sessionmaker, Session

# 用于生成时间戳
from datetime import datetime

# Pydantic 模型, 用于接口返回数据格式
from pydantic import BaseModel

# 数据库配置 (使用 SQLite 本地文件数据库, 无需安装数据库服务)
SQLALCHEMY_DATABASE_URL = "sqlite:///./chat_history.db"

# 创建数据库引擎
# check_same_thread=False 是 SQLite 必须加的参数
engine = create_engine(SQLALCHEMY_DATABASE_URL, connect_args={"check_same_thread": False})

# 创建会话工厂: 操作数据库必须用会话
SessionLocal = sessionmaker(autocommit=False, autoflush=False, bind=engine)

# 所有数据库表都要继承这个 Base
Base = declarative_base()

```

```

# ===== 数据库表模型 =====
# 定义一张表, 表名: chat_history
class ChatHistory(Base):
    __tablename__ = "chat_history" # 数据库里真实的表名

    id = Column(Integer, primary_key=True, index=True) # 主键ID, 自增
    user_id = Column(String, index=True) # 用户ID, 建索引 (加速查询)
    prompt = Column(Text) # 用户问题 (长文本)
    response = Column(Text) # AI 回答
    created_at = Column(DateTime, default=datetime.utcnow) # 创建时间, 默认当前UTC时间

# 根据上面定义的表结构, 自动在本地创建数据库文件
Base.metadata.create_all(bind=engine)

# ===== 数据库依赖 (给FastAPI用) =====
# 依赖注入函数: 每次请求自动获取/关闭数据库连接
def get_db():
    db = SessionLocal() # 创建会话
    try:
        yield db # 把会话交给接口使用
    finally:
        db.close() # 请求结束自动关闭连接, 防止泄露

# Pydantic 模型: 用于返回聊天记录格式
class ChatRecord(BaseModel):
    user_id: str
    prompt: str
    response: str

```

作用

- 负责**存储聊天记录**
- 自动创建数据库文件 `chat_history.db`
- 提供安全的数据库连接方式

3. deepseek_optimize.py 详解

```

# 调用大模型用的 OpenAI 格式客户端
from openai import OpenAI

# 日志工具: 打印运行信息/报错
import logging

# 配置日志级别为 INFO (显示普通日志)
logging.basicConfig(level=logging.INFO)

# 创建日志对象, 名字叫 deepseek-api
logger = logging.getLogger("deepseek-api")

# ===== DeepSeek 客户端 =====
# 创建连接 DeepSeek 的客户端 (兼容 OpenAI 格式)

```

```

deepseek_client = OpenAI(
    api_key="你的API密钥",          # 你的API密钥
    base_url="https://api.deepseek.com/v1"          # 官方接口地址
)

```

作用

- 封装 **DeepSeek 大模型**调用客户端
- 供主服务直接使用

4. qwen_api.py 详解

```

# 日志工具
import logging

# 通义千问也兼容 OpenAI 格式，所以同样用 OpenAI 客户端
from openai import OpenAI

# 配置日志
logging.basicConfig(level=logging.INFO)
logger = logging.getLogger("qwen-api")

# ===== 通义千问客户端 =====
qwen_client = OpenAI(
    api_key="你的API-KEY",          # 通义千问 API-KEY
    base_url="https://dashscope.aliyuncs.com/compatible-mode/v1" # 阿里云地址
)

```

作用

- 封装 **通义千问** 调用客户端
- 与 DeepSeek 统一格式

5. agent_server.py 详解

```

# 日志
import logging

# FastAPI 核心：创建应用、异常、请求对象、依赖注入
from fastapi import FastAPI, HTTPException, Request, Depends

# 接口限流工具
from slowapi import Limiter, _rate_limit_exceeded_handler
from slowapi.errors import RateLimitExceeded
from slowapi.util import get_remote_address

# 数据库会话
from sqlalchemy.orm import Session

# 跨域中间件

```

```

from starlette.middleware.cors import CORSMiddleware

# 流式响应
from starlette.responses import StreamingResponse

# 导入数据库工具
from database import get_db, ChatHistory

# 导入模型客户端
from deepseek_optimize import deepseek_client
from qwen_api import qwen_client

# 导入请求参数模型
from fastapi_base import AgentRequest, ChatRequest

# ===== 基础配置 =====
# 创建 FastAPI 应用
app = FastAPI(title="多模型智能体统一服务")

# 配置跨域：允许所有域名访问（前端才能调用）
app.add_middleware(
    CORSMiddleware,
    allow_origins=["*"],          # 允许所有来源
    allow_credentials=True,       # 允许Cookie
    allow_methods=["*"],          # 允许所有请求方法
    allow_headers=["*"],          # 允许所有请求头
)

# 接口限流：按用户IP限制
limiter = Limiter(key_func=get_remote_address)
app.state.limiter = limiter

# 限流触发时自动返回异常
app.add_exception_handler(RateLimitExceeded, _rate_limit_exceeded_handler)

# 全局日志配置
logging.basicConfig(level=logging.INFO)
logger = logging.getLogger("agent")

# ===== 统一智能体接口 =====
# POST 接口：/agent/chat
@app.post("/agent/chat")
async def agent_chat(
    req: AgentRequest,          # 接收请求参数
    request: Request,           # 请求对象
    db: Session = Depends(get_db) # 自动获取数据库会话
):
    # 如果选择通义千问
    if req.model == "qwen":
        return await qwen_chat(
            ChatRequest(**req.model_dump()), db # 转换参数并调用
        )

    # 如果选择 DeepSeek

```

```

elif req.model == "deepseek":
    return await deepseek_chat(
        request, ChatRequest(**req.model_dump())
    )
# 模型不支持
else:
    raise HTTPException(status_code=400, detail="模型不支持")

# 根路径测试
@app.get("/")
def root():
    return {"status": "running", "msg": "智能体服务已启动"}

# ===== DeepSeek 聊天接口 =====
@app.post("/deepseek/chat")
@limiter.limit("10/minute") # 限流: 每分钟最多10次
async def deepseek_chat(request: Request, chat_req: ChatRequest):
    try:
        # 调用 DeepSeek API
        response = deepseek_client.chat.completions.create(
            model="deepseek-chat",
            messages=[{"role": "user", "content": chat_req.prompt}],
            temperature=chat_req.temperature,
            stream=chat_req.stream
        )

        # 如果开启流式输出
        if chat_req.stream:
            async def stream_resp():
                for chunk in response:
                    if chunk.choices[0].delta.content:
                        yield f"data: {chunk.choices[0].delta.content}\n\n"

            return StreamingResponse(stream_resp(), media_type="text/event-stream")
        # 非流式, 直接返回完整回答
        else:
            return {"response": response.choices[0].message.content}

    # 异常处理
    except Exception as e:
        logger.error(f"DeepSeek error: {str(e)}")
        raise HTTPException(status_code=503, detail="模型服务异常")

# ===== 通义千问接口 =====
@app.post("/qwen/chat")
async def qwen_chat(
    request: ChatRequest,
    db: Session = Depends(get_db)
):
    # 如果有历史消息就用, 没有就空列表
    messages = request.history or []
    # 把当前用户问题加入消息列表
    messages.append({"role": "user", "content": request.prompt})

```



```
# 调用通义千问
response = qwen_client.chat.completions.create(
    model="qwen-turbo",
    messages=messages,
    temperature=request.temperature
)

# 提取回答
answer = response.choices[0].message.content

# 把对话存入数据库
db.add(ChatHistory(
    user_id=request.user_id,
    prompt=request.prompt,
    response=answer
))
db.commit() # 提交保存

# 返回回答 + token 使用量
return {"response": answer, "usage": dict(response.usage)}
```

作用

- 整个后端的大脑
- 统一接口 `/agent/chat` 自动路由到不同模型
- 支持流式输出、限流、跨域、数据库记录

运行

```
uvicorn agent_server:app --reload --debug
```

openapi访问

公共大模型API

POST

/agent/chatAgent Chat

CancelReset

Parameters

No parameters

Request body required

application/json

Edit ValueSchema

```
{  "model": "qwen",  "prompt": "你好，请介绍一下你自己",  "user_id": "test_user_001",  "stream": false,  "temperature": 0.7}
```

Execute

Clear

Responses

Curl

```
curl -X 'POST' \  'http://127.0.0.1:8000/agent/chat' \  -H 'accept: application/json' \  -H 'Content-Type: application/json' \  -d '{  "model": "qwen",  "prompt": "你好，请介绍一下你自己",  "user_id": "test_user_001",  "stream": false,  "temperature": 0.7}'
```

Request URL

```
http://127.0.0.1:8000/agent/chat
```

Server response

CodeDetails

200

Response body

```
{  "response": "你好！我是通义千问，是阿里巴巴集团旗下的通义实验室自主研发的超大规模语言模型。我能够回答问题、创作文字、逻辑推理、编程等，可以支持多语言交流，包括中文、英文、法语、西班牙语、葡萄牙语、俄语、土耳其语、韩语、日语、阿拉伯语等。\\n\\n我的训练数据涵盖了大量的文本信息，这使得我能够在多种任务上表现出色。不过，我也在不断学习和进步中，如果你有任何问题或需要帮助，欢迎随时告诉我！",  "usage": {    "completion_tokens": 111,    "prompt_tokens": 16,    "total_tokens": 127,    "completion_tokens_details": null,    "prompt_tokens_details": {      "audio_tokens": null,      "cached_tokens": 0    }  }}
```

Download

千问API访问

POST

/qwen/chat

Qwen Chat

Parameters

No parameters

Request body

required

application/json

Edit Value

Schema

```
[{"user_id": "test_user_001", "prompt": "你好，请介绍一下你自己。", "stream": false, "temperature": 0.7, "max_tokens": 1024, "history": []}]
```

Execute

Clear

Responses

Curl

```
curl -X 'POST' \
'http://127.0.0.1:8000/qwen/chat' \
-H 'accept: application/json' \
-H 'Content-Type: application/json' \
-d '{
  "user_id": "test_user_001",
  "prompt": "你好，请介绍一下你自己。",
  "stream": false,
  "temperature": 0.7,
  "max_tokens": 1024,
  "history": [
  ]
}'
```

Request URL

```
http://127.0.0.1:8000/qwen/chat
```

Server response

Code

Details

200

Response body

```
{
  "response": "你好！我是通义千问，是阿里巴巴集团旗下的通义实验室自主研发的超级大规模语言模型。我能够回答问题、创作文字、逻辑推理、编程等，支持多种语言。我的目标是成为你的智能助手，帮助你更高效地获取信息和完成任务。有什么我可以帮你的吗？",
  "usage": {
    "completion_tokens": 65,
    "prompt_tokens": 17,
    "total_tokens": 82,
    "completion_tokens_details": null,
    "prompt_tokens_details": {
      "audio_tokens": null,
      "cached_tokens": 0
    }
  }
}
```

Download

Deepseek访问

POST /deepseek/chat Deepseek Chat

Parameters

Cancel

Reset

No parameters

Request body required

application/json

Edit Value

Schema

```
{  "user_id": "test_user_001",  "prompt": "你好，请介绍一下你自己。",  "stream": false,  "temperature": 0.7,  "max_tokens": 1024,  "history": []}
```

Execute

Clear

Responses

Curl

```
curl -X 'POST' \  'http://127.0.0.1:8000/deepseek/chat' \  -H 'accept: application/json' \  -H 'Content-Type: application/json' \  -d '{  "user_id": "test_user_001",  "prompt": "你好，请介绍一下你自己。",  "stream": false,  "temperature": 0.7,  "max_tokens": 1024,  "history": []  }'
```

Request URL

http://127.0.0.1:8000/deepseek/chat

Server response

Code

Details

200

Response body

```
{  "response": "你好！很高兴认识你！👋🏻我是**DeepSeek**，由深度求索公司创造的AI助手。让我简单介绍一下自己的特点：\n\n**基本信息**：\n- 纯文本对话模型，擅长理解和生成各种文字内容\n- 知识截止日期：2025年5月\n- 完全免费使用，无需担心收费问题\n\n**我的能力**：\n- **阅读链接**：可以访问你分享的网页链接\n- **文件处理**：支持上传图片、PDF、Word、Excel、PPT、TXT等文件，从中提取文字信息\n- **联网搜索**：需要你在Web/App端手动开启联网搜索功能\n- **语音输入**：App端支持语音输入，更便捷\n- **超长上下文**：1M上下文窗口，可以一次性处理《三体》三部曲那么大体量的内容\n\n**使用方式**：\n- Web端直接访问\n- App端可通过官方应用商店下载\n\n我会用热情、细腻的方式回答你的问题，尽我所能提供帮助。无论是学习、工作还是日常生活中的疑问，都欢迎随时问我！\n\n有什么我可以帮你的吗？🤖
```

Download

Response headers

6. Streamlit 前端

```
# 前端 UI 框架
import streamlit as st

# 发送 HTTP 请求给后端
import requests

# 生成唯一用户ID
import uuid

# 设置页面标题、布局
st.set_page_config(page_title="多模型智能体", layout="wide")

# 页面大标题
st.title("🤖 通义千问 & DeepSeek 智能体")
```

```

# 后端接口地址
API_URL = "http://localhost:8000/agent/chat"

# ===== 会话状态 =====
# 如果没有 user_id, 自动生成一个唯一ID (每个浏览器不一样)
if "user_id" not in st.session_state:
    st.session_state.user_id = str(uuid.uuid4())

# 存储聊天历史
if "messages" not in st.session_state:
    st.session_state.messages = []

# ===== 侧边栏 =====
with st.sidebar:
    model = st.selectbox("选择模型", ["qwen", "deepseek"])
    temperature = st.slider("生成温度", 0.0, 1.0, 0.7)

# ===== 展示历史消息 =====
for msg in st.session_state.messages:
    with st.chat_message(msg["role"]):
        st.markdown(msg["content"])

# ===== 用户输入 =====
if prompt := st.chat_input("输入问题..."):
    # 把用户消息存入状态
    st.session_state.messages.append({"role": "user", "content": prompt})

    # 显示用户消息
    with st.chat_message("user"):
        st.markdown(prompt)

    # 请求后端并显示回答
    with st.chat_message("assistant"):
        resp = requests.post(API_URL, json={
            "model": model,
            "prompt": prompt,
            "user_id": st.session_state.user_id,
            "temperature": temperature
        }).json()

        answer = resp["response"]
        st.markdown(answer)

    # 把AI回答存入状态
    st.session_state.messages.append({"role": "assistant", "content": answer})

```

作用

- 可视化聊天界面
- 自动生成用户 ID
- 选择模型、调节温度
- 调用后端 `/agent/chat` 接口

前端界面

运行

```
streamlit run streamlit_frontend.py
```

选择模型

deepseek

生成温度

0.99

☹️ 通义千问 & DeepSeek 智能体

👤 你好啊

🤖 你好！很高兴见到你，有什么我可以帮你的吗？ 😊

👤 介绍下自己

🤖 你好！我是通义千问，是阿里巴巴集团旗下的通义实验室自主研发的超大规模语言模型。我能够回答问题、创作文字、逻辑推理、编程等，可以帮你在工作和生活中更高效地完成各种任务。

我的训练数据涵盖了大量的文本信息，包括书籍、文章、网页等，这让我能够理解和生成多种语言的内容。我可以进行多轮对话，理解上下文，并根据用户的反馈不断优化回答。

如果你有任何问题或需要帮助，随时告诉我，我会尽力提供支持！ 😊

👤 你是谁

输入问题...

⬆